Examen domiciliario de R

Laboratorio para el Análisis de Datos Económicos y Financieros

Kevin Burghardt[1]

Santino Domanico[2]

Sebastián Roballos[3]

Licenciatura en Economía

Segundo Semestre 2026

Profesores: Ian Bounos y Pedro Dolanyi Plaza

Octubre 2026



[1] kburghardt@mail.utdt.edu
[2] sdomanico@mail.utdt.edu
[3] sroballos@mail.utdt.edu

1. Análisis de datos: Oil & Gas no convencional en Argentina

Preguntas

1. ¿Cuáles son los grandes *players* del Oil & Gas en Argentina y cómo se reparten el mercado? Definimos "gran *player*" a aquellas empresas que estén en el top cinco de mayor *market share* en términos de cantidades a lo largo de todo el *dataset*:

$$s_i = \frac{q_i}{\sum_j q_j},$$

   donde q_i es la producción de la empresa i.

2. ¿Petróleo o gas, cómo creció cada uno?

3. ¿Los recursos se extraen de piedra Shale o Tight, cómo evolucionó?

Descripción del dataset

¿Qué son Shale y Tight? Básicamente, el tipo de piedra donde está el recurso natural. Extraer recursos de piedra Tight es más barato y tiene menor complejidad tecnológica que de piedra Shale. Sin embargo, cuando se extraen recursos de piedra Shale (que es capital intensivo y de mayor complejidad) se obtiene mayor cantidad. Es razonable hipotetizar que el tipo de roca en que se trabaja refleja la madurez del proyecto, la inversión, la calidad de los *players* y las expectativas de retorno.

Aclaraciones metodológicas. Tomamos 2014 como inicio de la muestra porque antes de ese año no había suficientes observaciones como para obtener conclusiones significativas (entre 1.700 y 5.200 registros por año en 2006–2013, contra 8.777 en 2014 y en aumento). 2026 lo excluimos porque, al ser el año en curso, tiene menos registros que el resto. El universo de análisis va de 2014 a 2025 inclusive. Todo el *dataset* (y por ende las conclusiones) es sobre producción de gas y petróleo **no convencional**.

Algunas empresas aparecen con más de un nombre porque lo cambiaron durante el período del *dataset*. Si no los unificamos, una misma empresa se cuenta como varias y su *market share* queda subestimado. Unificamos al nombre más reciente.

Visualización preliminar

Pregunta 1: grandes *players*

Primero gas: a lo largo de los años, YPF, Tecpetrol, Total Austral, Pampa Energía y Pan American Energy se reparten el 81 % del *market share*.

YPF es más dominante en el mercado del petróleo que en el del gas y es top uno en *market share* en ambos. En el mercado del petróleo aparecen jugadores distintos a los del gas, como Shell, Vista Energy y Pluspetrol, mientras que Tecpetrol cae al sexto puesto. Los top cinco *players* se reparten el 87 % del mercado: el mercado del petróleo en Argentina está más concentrado que el del gas. Es interesante a su vez ver la evolución de estos *players* a lo largo de los años.

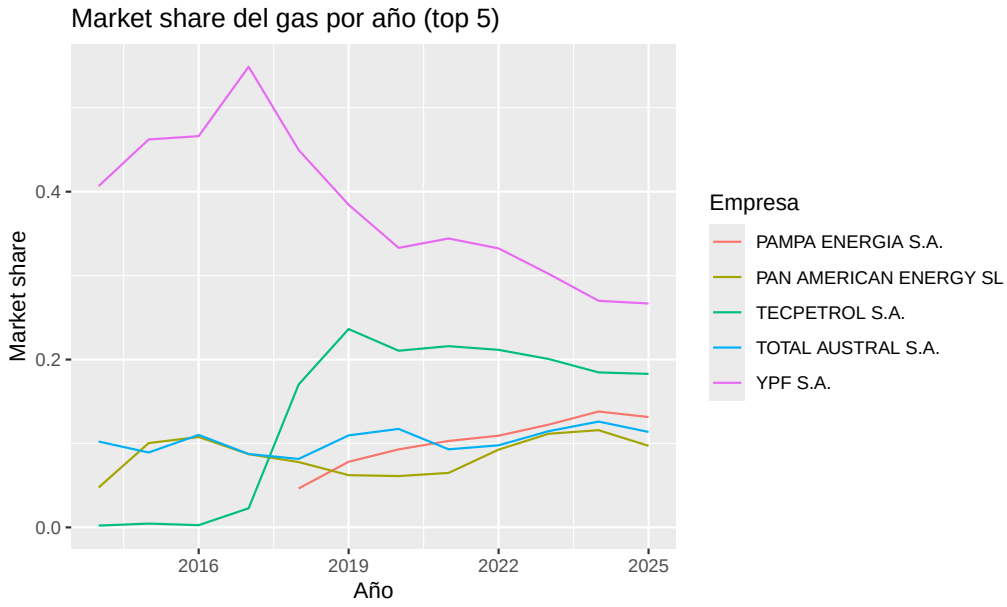


Figura 1: *Market share* del gas por año (top 5)

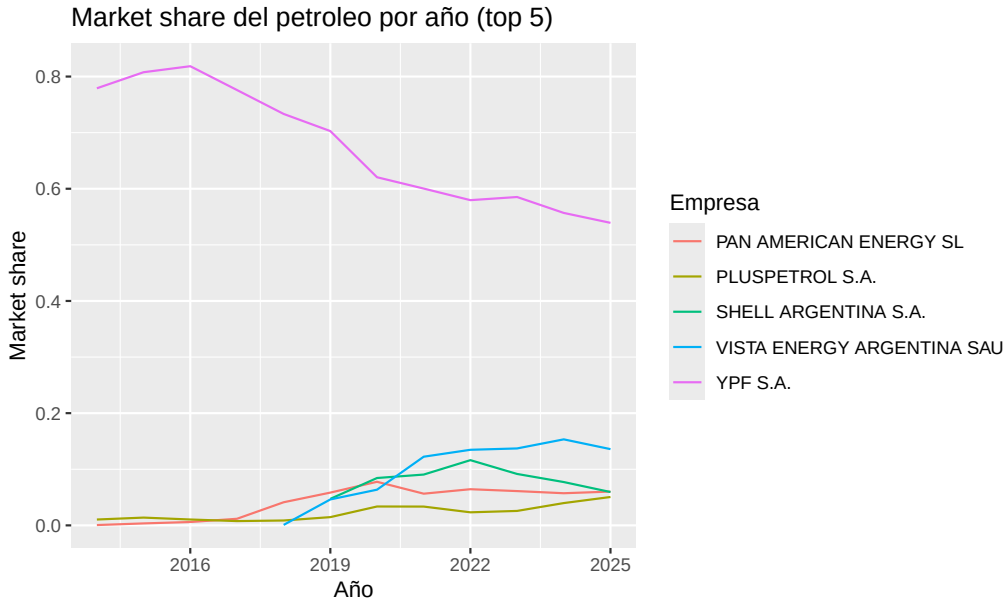


Figura 2: *Market share* del petróleo por año (top 5)

Dado el *feedback* obtenido en las clases, también hacemos el gráfico *stacked area*, que muestra de forma más ilustrativa la concentración de mercado y es más fácil de interpretar.

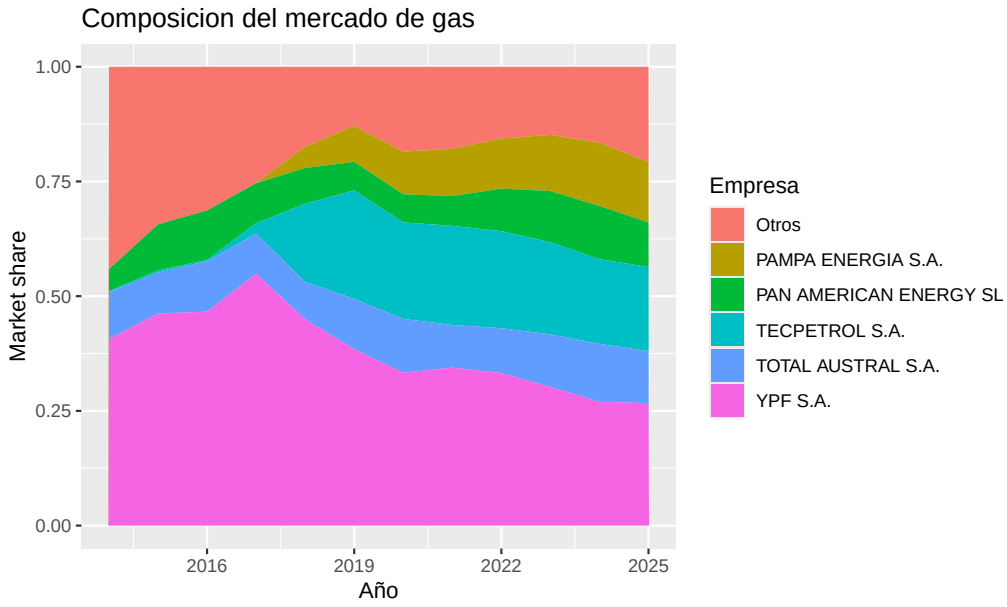


Figura 3: Composición del mercado de gas

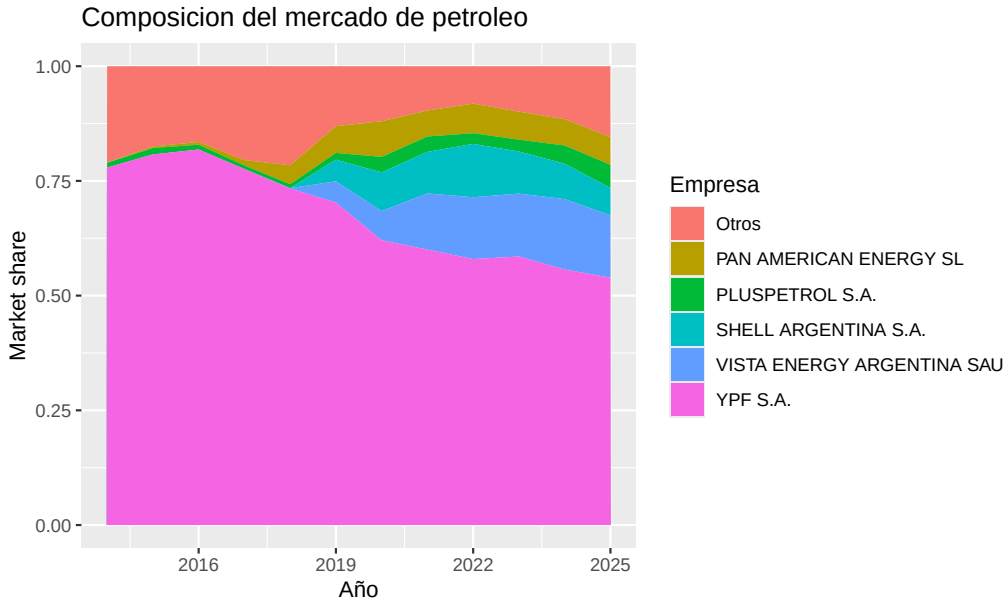


Figura 4: Composición del mercado de petróleo

En ambas industrias podemos ver un claro dominio de YPF que se ha moderado llegando hacia la actualidad. Jugadores como Vista, Pan American y Shell ayudaron a la diversificación del mercado (en el caso del petróleo), fenómeno que se repite en el gas con Pampa Energía y Pan American.

Otro detalle interesante es que Vista (2018), Shell (2019) y Pampa Energía (2018) lograron posicionarse en el top 5 de *market share* siendo jugadores relativamente nuevos en el Oil & Gas no convencional argentino.

Pregunta 2: crecimiento del petróleo y del gas

Como están en unidades distintas, comparamos índices de crecimiento con año base:

$$I_t = \frac{Q_t}{Q_{2014}} \times 100,$$

donde Q_t es la producción en el año t.

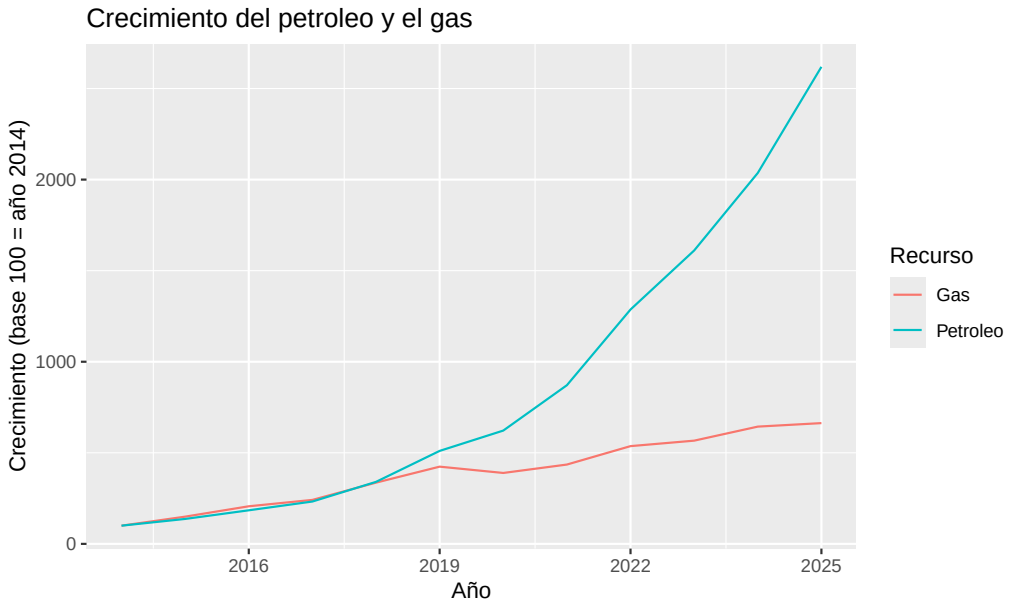


Figura 5: Crecimiento del petróleo y el gas (base 100 = año 2014)

Las curvas se movieron juntas al principio y luego divergen. Nos interesa saber cuándo fue la última vez que se cruzaron, para ver cuándo empezó la divergencia. Definiendo

$$D_t = I_t^{\text{petróleo}} - I_t^{\text{gas}},$$

por Bolzano, si D_t cambia de signo, las curvas se cruzaron.

Hasta 2017 el crecimiento de la producción de gas era mayor al del petróleo; de 2018 en adelante, el crecimiento del petróleo superó ampliamente al del gas.

Es interesante observar el crecimiento de la producción de petróleo y gas junto con lo observado en la pregunta 1 sobre los *players*: hay una coincidencia temporal entre la entrada de nuevos *players*, una menor concentración de mercado y el aumento de la producción de petróleo.

Pregunta 3: Shale o Tight

La pregunta "Shale o Tight" complementa los incisos anteriores. Vimos que hacia 2018–2020 aumentó la producción de petróleo (exponencialmente) y de gas (más suavemente), que la concentración de mercado cayó y que entraron nuevos *players*. Recordemos que extraer recursos de roca Shale es más complejo y caro, pero a su vez produce una cantidad notablemente mayor que explotar roca Tight. Mayor explotación de roca Shale se relaciona con mayor confianza, inversión y madurez del proyecto.

Hasta 2021 había una dominancia de la roca Tight; ese año la tendencia se revirtió y la explotación de roca Shale siguió creciendo hasta hoy.

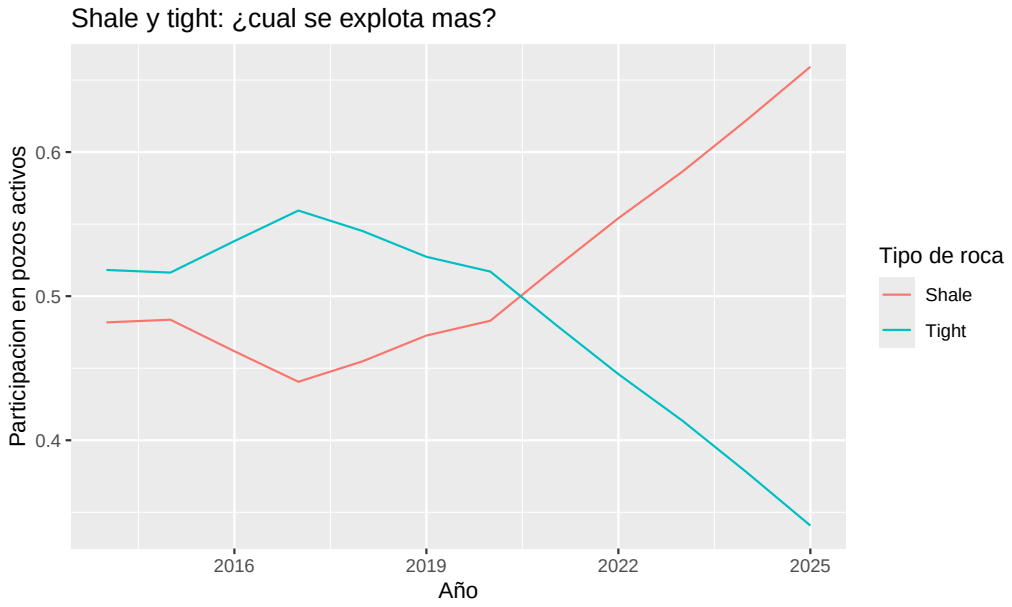


Figura 6: Participación de Shale y Tight en los pozos activos

Conclusiones del análisis de datos

1. Antes de 2014 había pocas observaciones y ningún análisis hubiese sido riguroso, por lo que lo descartamos del universo de análisis.

2. YPF es la empresa dominante tanto en gas como en petróleo, pero tanto su participación como la concentración del mercado en general fueron cayendo desde la segunda mitad de los 2010s.

3. La producción de gas creció más hasta 2017; de 2018 en adelante el petróleo pasó a liderar el crecimiento y la tendencia continúa.

4. En 2021 la explotación de roca Shale superó a la de Tight, lo que valida la hipótesis inicial. Mayor explotación de roca Shale está vinculada con una industria más madura, confiable y redituable.

5. Hacia finales de la década de 2010 la industria cambió: entraron nuevos *players* y el producto estrella pasó a ser el petróleo. Años después, la madurez de la industria se reflejó en proyectos más intensivos en capital y tecnología (explotación de roca Shale).

2. Análisis econométrico: gapminder

Parte 1: Ingreso por persona

Punto 1: Evolución temporal en Argentina

Entre 1960 y 1974, el ingreso per cápita de Argentina en dólares crece, pasando de 9.800 a 14.700. Luego, se mantiene en ese nivel hasta 1980. Entre 1980 y 1990 cae hasta unos 11.400, se recupera en los noventa hasta casi 16.000 en 1998 y vuelve a caer en la crisis de 2001–2002 hasta unos 12.500 en 2002. Desde entonces crece con fuerza hasta unos 18.900 en 2010, con una caída en 2009. Por lo tanto, no es una serie de crecimiento estable, sino que alterna tramos de ascenso, estancamiento y crisis, condicionando cualquier ajuste simple (como veremos en el siguiente inciso).

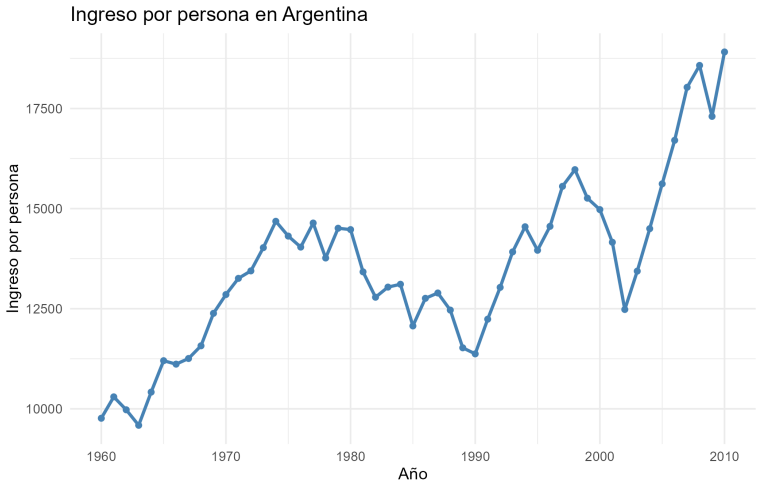


Figura 7: Ingreso por persona en Argentina

Punto 2: Modelos lineal, cuadrático y de grado 10

Entrenamos con 1960–2000 (41 observaciones) y reservamos 2001–2010 (10 observaciones) para testear. Lógicamente, al aumentar el grado del polinomio, el ajuste dentro de la muestra mejora mucho: el R^2 de entrenamiento pasa de 0,451 (lineal) a 0,498 (cuadrático) y a 0,943 (grado 10), y el RECM de entrenamiento baja de 1.213 a 1.160 y a 393 (Figura 8 y Tabla 1). Con un polinomio de grado 10, la curva adquiere la flexibilidad suficiente para seguir cada oscilación particular de la serie temporal.

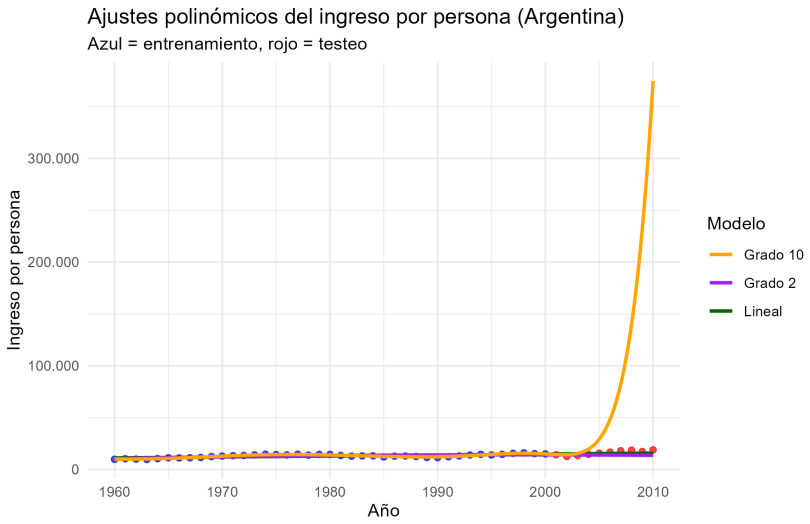


Figura 8: Ajustes lineal, de grado 2 y de grado 10 (azul: entrenamiento, rojo: testeo)

Fuera de la muestra el orden se invierte. El RECM de testeo es de aproximadamente 2.012 para el modelo lineal, 3.114 para el de grado 2 y 138.837 para el de grado 10. Este último se dispara a partir de 2004 y hacia 2010 supera los 300.000, cuando el ingreso observado ese año es de 19.000. Por eso la Figura 9 omite donde supera 30.000, para poder ver los otros dos modelos.

Modelo	R^2 (entrenamiento)	RECM (entrenamiento)	RECM (testeo)
Lineal	0,451	1.213	2.012
Polinómico grado 2	0,498	1.160	3.114
Polinómico grado 10	0,943	393	138.837

Tabla 1: Comparación de modelos en entrenamiento y en testeo

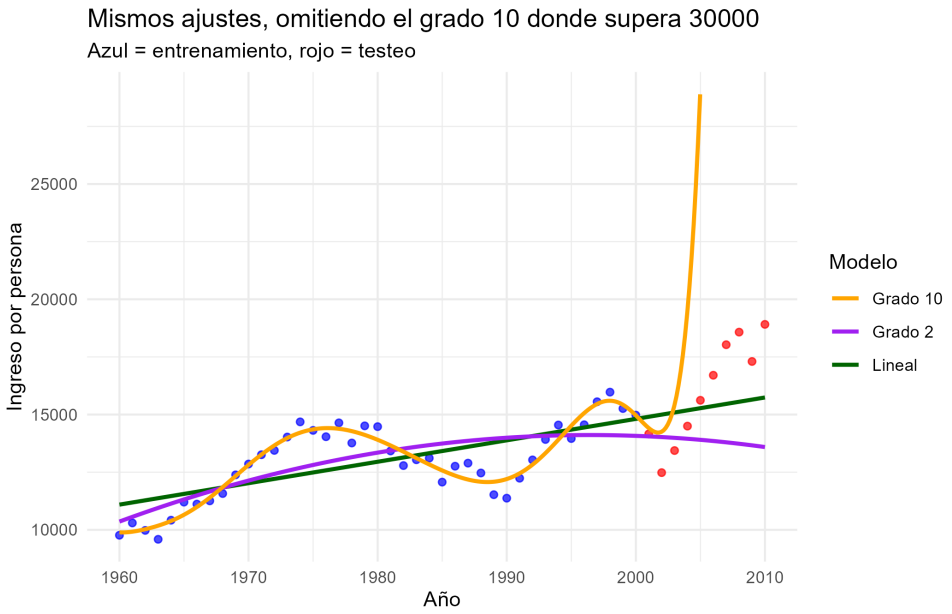


Figura 9: Mismos ajustes, omitiendo el grado 10 donde supera 30.000

La intuición es el balance entre sesgo y varianza: el modelo de grado 10 es tan flexible que se ajusta a todos los altibajos del entrenamiento, incluso a los shocks, en lugar de captar solo la tendencia de fondo (sobreajuste). Al extrapolar en el período de testeo, los polinomios de alto grado divergen y se vuelven absurdos. Que el modelo lineal gane en testeo no lo hace un buen modelo per se (en entrenamiento explica menos de la mitad de la variación), sino simplemente el que menos se equivoca al extrapolar.

Punto 3: Matrices de correlación (Brazil, Chile, Peru y Uruguay)

Las correlaciones entre los niveles de ingreso (Tabla 2) van de 0,549 (Chile–Peru) a 0,941 (Chile–Uruguay), y las de Argentina con cada uno de los otros cuatro países están entre 0,765 y 0,829. Que sean tan altas es esperable: casi todas las series crecen a lo largo de cincuenta años, y dos variables con tendencia suelen estar muy correlacionadas aunque no tengan nada que ver entre sí. La correlación de niveles mide sobre todo que ambas suben con el tiempo. Peru es el menos correlacionado con el resto (0,549 a 0,782), y el gráfico lo muestra: su ingreso cae a fines de los ochenta y recién despega después de 2002.

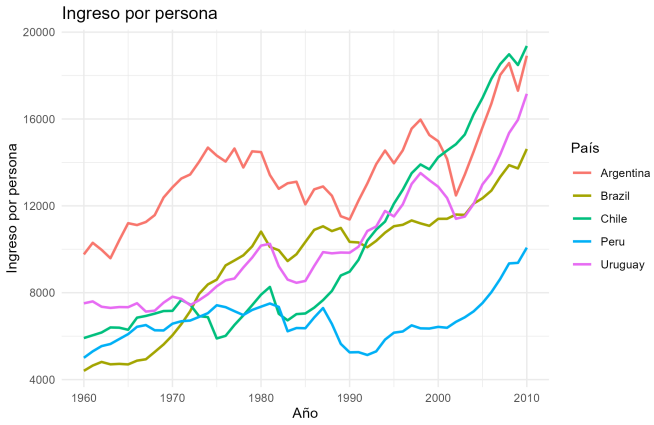


Figura 10: Ingreso por persona de los cinco países

	Argentina	Brazil	Chile	Peru	Uruguay
Argentina	1	0,795	0,765	0,782	0,829
Brazil	0,795	1	0,772	0,565	0,871
Chile	0,765	0,772	1	0,549	0,941
Peru	0,782	0,565	0,549	1	0,577
Uruguay	0,829	0,871	0,941	0,577	1

Tabla 2: Correlaciones entre los niveles de ingreso por persona

Las correlaciones entre las variaciones porcentuales anuales (Tabla 3) son mucho más bajas. Van de 0,006 (Brazil–Chile) a 0,513 (Argentina–Uruguay), y las de Argentina con los otros cuatro van de 0,169 (Chile) a 0,513 (Uruguay). Al sacar la tendencia queda lo que realmente se mueve en conjunto: los shocks comunes y el ciclo regional. El par más correlacionado, Argentina–Uruguay, comparte la crisis de 2001–2002, que aparece como una caída en ambas series (Figura 10); en cambio, Brazil y Chile prácticamente no se mueven juntos. Ninguna correlación supera 0,52, el ciclo de cada economía es en buena parte propio. La diferencia entre las dos matrices muestra que, para saber si dos economías se mueven juntas, conviene mirar las variaciones y no los niveles.

	Argentina	Brazil	Chile	Peru	Uruguay
Argentina	1	0,272	0,169	0,355	0,513
Brazil	0,272	1	0,006	0,411	0,278
Chile	0,169	0,006	1	0,043	0,366
Peru	0,355	0,411	0,043	1	0,413
Uruguay	0,513	0,278	0,366	0,413	1

Tabla 3: Correlaciones entre las variaciones porcentuales anuales

Parte 2: Esperanza de vida y género

Aclaraciones metodológicas. Elegimos 2010 por ser el último año del dataset (193 países). Los datos faltantes en las series por género ("-" en `life_expectancy_female` y -999 en `life_expectancy_male`) se codificaron como NA, dejando 184 países con datos completos para los puntos 5 a 8. Mantenemos a Haití pese al quiebre de su esperanza total (32,5 años por el terremoto de 2010 frente a 62,5 en la serie femenina proyectada) y evaluamos la robustez sin él. Los contrastes se realizaron a mano mediante la distribución t.

Punto 5: Life expectancy vs. life expectancy female

La relación es positiva, casi lineal y muy fuerte (correlación de 0,935). Casi todos los países quedan por debajo de la recta de 45°: la esperanza de vida total es, en general, menor que la femenina. Haiti es el único punto claramente alejado de la nube.

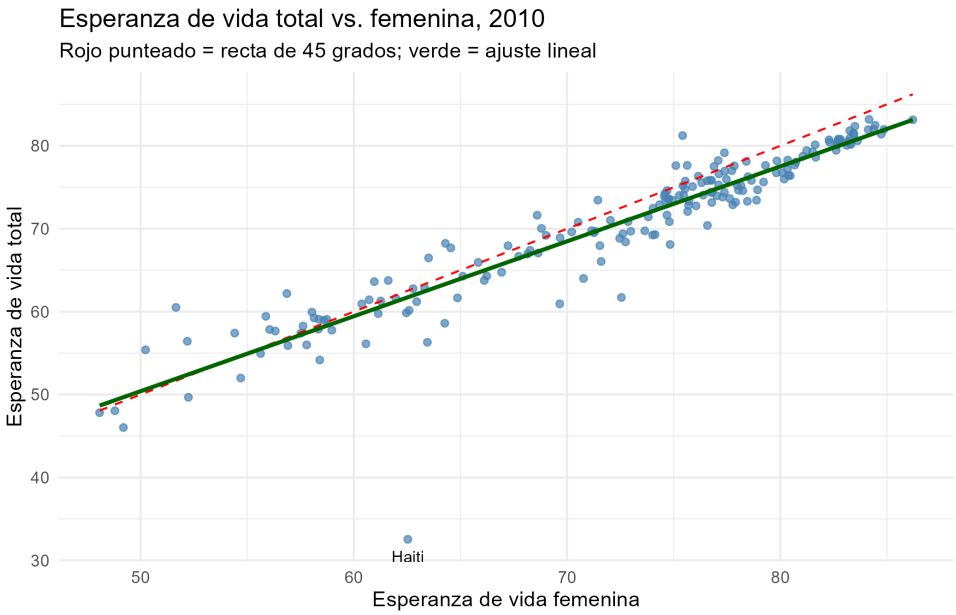


Figura 11: Esperanza de vida total vs. femenina, 2010

Punto 6: Regresión simple

Estimamos el modelo por MCO:

$$\widehat{\text{esperanza_total}} = \underset{(1{,}85)}{5{,}22} + \underset{(0{,}025)}{0{,}904}\,\text{esperanza_femenina}, \quad R^2 = 0{,}874.$$

Un año adicional de esperanza de vida femenina se asocia con un incremento de 0,9 años en la total. Al contrastar $H_0\colon \beta_1 = 1$, obtenemos $t = -3{,}79$, rechazando la relación de uno a uno.

Excluyendo el caso atípico de Haití, el R^2 asciende a 0,926 ($b_1 = 0{,}886$), lo que confirma que esa sola observación explicaba una porción sustancial de la varianza residual.

El elevado R^2 no debe interpretarse como causalidad. La esperanza de vida total es un promedio ponderado de ambas, por lo que las variables están vinculadas por definición.

Punto 7: Test de hipótesis

Dado que cada país aporta dos mediciones sobre la misma población, trabajamos con datos pareados definiendo $d_i = \text{femenina}_i - \text{total}_i$. Contrastamos:

$$H_0\colon \mathbb{E}[d] = 0 \quad \text{vs.} \quad H_1\colon \mathbb{E}[d] > 0$$

La evidencia empírica es contundente a favor de una mayor sobrevida femenina: la diferencia media es de 1,72 años a favor de las mujeres y se rechaza H_0 con holgura ($t = 7{,}1$, $p = 1{,}3\times10^{-11}$, con un IC del 95 % de [1,25; 2,20]). Este patrón se cumple en el 80 % de los países y resulta plenamente robusto a la exclusión de Haití (media de 1,57 años y $t = 8{,}34$).

En la práctica, como la esperanza de vida total es simplemente el promedio ponderado entre hombres y mujeres, que el test rechace es una consecuencia matemática directa de que las mujeres viven más que los varones; en el fondo, lo que el test cuantifica es la brecha de género.

Punto 8: Regresión múltiple (+ income per person)

Incorporamos el ingreso por persona (expresado en miles de dólares) al modelo:

$$\widehat{\text{esperanza_total}} = \underset{(2,03)}{5,15} + \underset{(0,031)}{0,866}\,\text{esperanza_femenina} + \underset{(0,015)}{0,032}\,\text{ingreso}.$$

Manteniendo el ingreso constante, un año adicional de sobrevida femenina se asocia con un incremento de 0,87 años en el promedio nacional. Por su parte, cada USD 1.000 adicionales de ingreso per cápita se asocian con un aumento de apenas 0,032 años de esperanza de vida. Al controlar por ingreso, el coeficiente de la esperanza femenina apenas se reduce de 0,904 a 0,866.

Como se observa en la Tabla 4, aunque el ingreso resulta estadísticamente significativo al 5 %, su aporte empírico es marginal: el R^2 prácticamente no varía (de 0,874 a 0,877) y el RECM de testeo fuera de muestra permanece estancado en 2,92 años. Por ende, no se justifica incluirlo, ya que la variable femenina contiene prácticamente toda la información predictiva del modelo.

Modelo	R^2	R^2 ajustado	RECM de testeo
Simple	0,8743	0,8736	2,93
Múltiple (con ingreso)	0,8772	0,8759	2,92

Tabla 4: Regresión simple vs. múltiple (RECM de testeo promedio sobre 200 particiones 70/30)

Punto 9: Modelo final (máximo 3 covariables)

Excluimos `life_expectancy_female` (lo pide la consigna) y `life_expectancy_male` (es parte de lo que se quiere explicar), `country` y `year` (identificadores), `income_groups` (clasificación por nivel de ingreso, redundante), `world_region` (6 categorías, equivale a 5 variables y excede el máximo de tres), `main_religion` (algunos NA y categorías mal escritas) y `population` (sin razón clara para explicar la esperanza de vida). Quedaron como candidatas el ingreso, la mortalidad de menores de 5 años, la fecundidad y la pertenencia a la OCDE.

Por la asimetría del ingreso y sus rendimientos marginales decrecientes, evaluamos su logaritmo (cuya correlación con la esperanza de vida asciende de 0,59 a 0,78). Con los 184 países de la muestra, comparamos nueve modelos evaluando su RECM promedio de testeo sobre 200 particiones aleatorias 70/30 idénticas (Tabla 5), considerando mortalidad infantil (*Mort.*), ingreso per cápita (*Ing.*), fecundidad (*Fecund.*) y membresía a la OCDE como dummy.

Modelo	R^2	R^2 aj.	RECM test
Ingreso	0,346	0,343	7,43
log(Ingreso)	0,609	0,607	5,58
Mort. < 5	0,784	0,783	4,23
log(Mort. < 5)	0,769	0,768	4,30
Mort. + log(Ing.)	0,812	0,810	3,97
log(Mort.) + log(Ing.)	0,774	0,772	4,28
Mort. + log(Ing.) + Fecund.	0,815	0,812	3,97
Mort. + log(Ing.) + OCDE	**0,823**	**0,820**	**3,86**
log(Ing.) + Fecund. + OCDE	0,677	0,672	5,09

Tabla 5: Modelos candidatos (en negrita, el elegido por menor RECM de testeo)

El mejor modelo (fila en negrita de la Tabla 5) es:

$$\widehat{\text{esperanza_vida}} = 63,80 - \underset{(0,007)}{0,154^{***}}\,\text{mortalidad} + \underset{(0,240)}{1,341^{***}}\,\log(\text{ingreso}) + \underset{(0,531)}{3,01^{***}}\,\text{OCDE},$$

con $R^2 = 0{,}823$ y R^2 ajustado $= 0{,}820$. El efecto marginal de la mortalidad infantil es de $-0{,}15$ años sobre la esperanza de vida; el del ingreso, con 0,013 años más; y los países de la OCDE tienen 3,0 años más, a igual mortalidad e ingreso. Los tres coeficientes son significativos.

La mortalidad de menores de 5 años está ligada a la esperanza de vida por construcción (muertes tempranas bajan el promedio), por lo que el modelo es más predictivo que explicativo (el candidato sin ella rinde claramente peor). El análisis de residuos (Figura 12) muestra que los países peor explicados presentan una sobreestimación sistemática, concentrada en África subsahariana (Eswatini, Sudáfrica, Lesotho, entre otros) y casos atípicos como Haití, reflejando la omisión de variables sanitarias e institucionales críticas no disponibles en la base de datos.

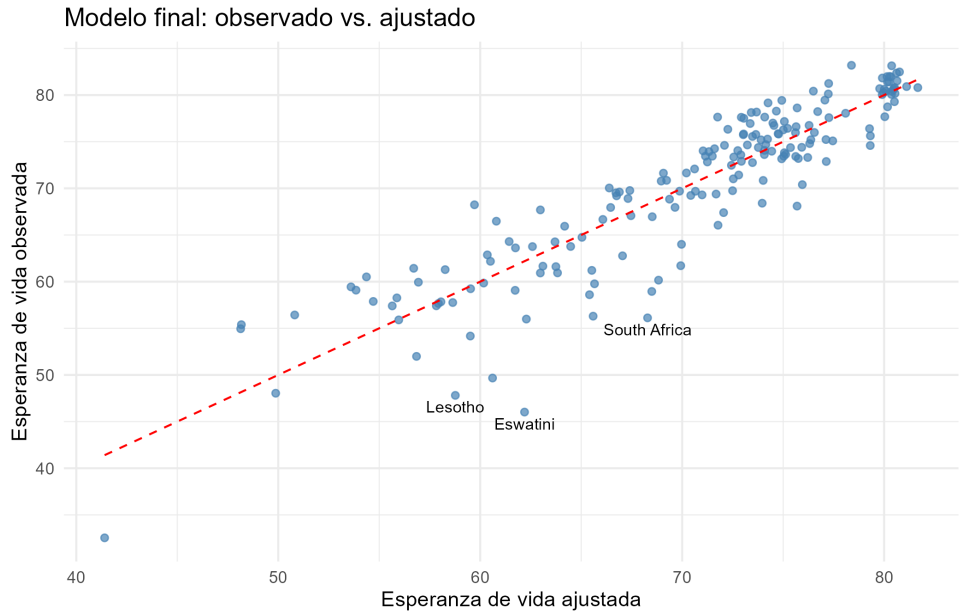


Figura 12: Modelo final: esperanza de vida observada vs. ajustada

Conclusiones del análisis econométrico

1. El ingreso de Argentina no sigue una tendencia estable: alterna crecimiento, estancamiento y crisis.

2. Un mayor grado del polinomio mejora el ajuste dentro de la muestra pero empeora la predicción: el grado 10 sobreajusta y explota al extrapolar. En testeo, el modelo lineal es el mejor de los tres probados.

3. Los niveles de ingreso de los países sudamericanos están muy correlacionados por la tendencia común; las variaciones anuales lo están mucho menos y reflejan el co-movimiento real.

4. La esperanza de vida total y la femenina están fuertemente relacionadas ($R^2 = 0{,}87$), sobre todo porque una es parte de la otra.

5. La esperanza de vida femenina supera significativamente a la total (diferencia media de 1,7 años): el test refleja la brecha de género.

6. Agregar el ingreso mejora muy poco el ajuste (R^2 de 0,874 a 0,877), por lo que no vale la pena incluirlo en esa regresión.

7. Para predecir la esperanza de vida con tres covariables, el mejor modelo usa mortalidad de menores de 5 años, log(ingreso) y pertenencia a la OCDE (R^2 ajustado de 0,82).

3. Simulación de demanda Cobb-Douglas

Elegimos el ejercicio de simulación 1: la demanda de dos bienes por parte de los hogares bajo preferencias Cobb-Douglas, $U(x_1, x_2) = x_1^{\alpha_1} x_2^{\alpha_2}$ con $\alpha_1 + \alpha_2 = 1$, sujeta a la restricción presupuestaria $p_1 x_1 + p_2 x_2 \leq Y$. Las funciones auxiliares están definidas en `simulacion/funciones.R` y se cargan con `source()` desde el script principal.

Setup y funciones

Fijamos la semilla en 26/07/1842, la fecha de nacimiento del gran economista Alfred Marshall, para garantizar la reproducibilidad. Los parámetros de la simulación son:

Parámetro	Valor
Cantidad de hogares (n)	10.000
Precio del bien 1 (p_1)	10
Precio del bien 2 (p_2)	5
Preferencia por el bien 1 (α_1)	0,6
Preferencia por el bien 2 (α_2)	0,4
Grados de libertad de la χ^2 (k)	1000

Generación de ingresos. La función `simular_ingreso(n, k)` genera n ingresos con distribución χ^2_k. Esta distribución tiene media k y varianza $2k$, por lo que elegimos k como el ingreso promedio deseado. Al aumentar k, la varianza *absoluta* ($2k$) crece linealmente, así que los ingresos se dispersan más en términos nominales. Pero la dispersión *relativa* (el desvío estándar sobre la media, $\sqrt{2/k}$) decrece: respecto a su media, los ingresos son más parejos. En pocas palabras, un k alto implica ingresos mayores y relativamente más homogéneos.

Demanda óptima. La función `demanda_cd(Y, p_1, p_2, a_1, a_2)` devuelve una lista con las demandas óptimas $x_1^* = \alpha_1 Y / p_1$ y $x_2^* = \alpha_2 Y / p_2$ y la utilidad indirecta $U^* = (x_1^*)^{\alpha_1} (x_2^*)^{\alpha_2}$.

Funciones auxiliares. La función `hist_resumen` grafica el histograma de un vector y reporta en el mismo gráfico su media y sus cuartiles, y la usamos para x_1^*, x_2^* y U^*. La función `prob_bajo_consumo(c, j, data)` estima la probabilidad de que $x_j^* < c$ como la proporción de hogares simulados cuya demanda del bien j es menor al umbral c.

Simulación base

Simulamos los ingresos de los 10.000 hogares y calculamos sus demandas y utilidades con los parámetros de la tabla anterior.

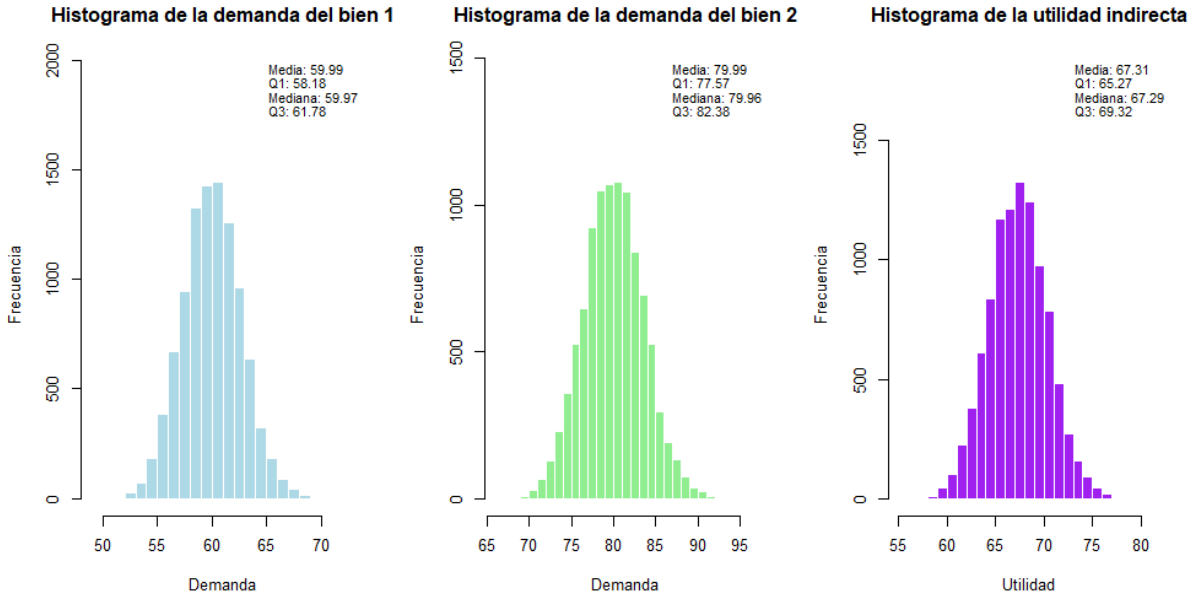


Figura 13: Historiograma de demandas y utilidad indirecta

Probabilidad de bajo consumo. Como umbral c usamos la media de la demanda del bien 1 menos un desvío estándar. Con este umbral, la probabilidad de bajo consumo del bien 1 es de 0,1585.

Shock de precios

Suponemos que el precio del bien 1 aumenta un 20 % ($p_1' = 1{,}2\,p_1$), mientras que p_2 y los ingresos Y permanecen constantes, y repetimos la simulación.

La diferencia entre medias es -10 para el bien 1 y 0 para el bien 2. Es decir, dado un aumento del 20 % del precio, cada hogar consume en promedio 10 unidades menos del bien 1 (la caída individual es proporcional) y ninguna unidad menos del bien 2. Tiene sentido que el consumo del bien 2 no se vea afectado, ya que su demanda óptima, $\alpha_2 Y/p_2$, no depende de p_1.

Visualización comparada. Superponemos los histogramas de x_1^* antes y después del shock, con colores transparentes y las medias marcadas con líneas punteadas para apreciar mejor el efecto. Como queremos ambos en un mismo gráfico, definimos cortes comunes y guardamos los histogramas con `plot = FALSE` para luego graficarlos con `plot(..., add = TRUE)`.

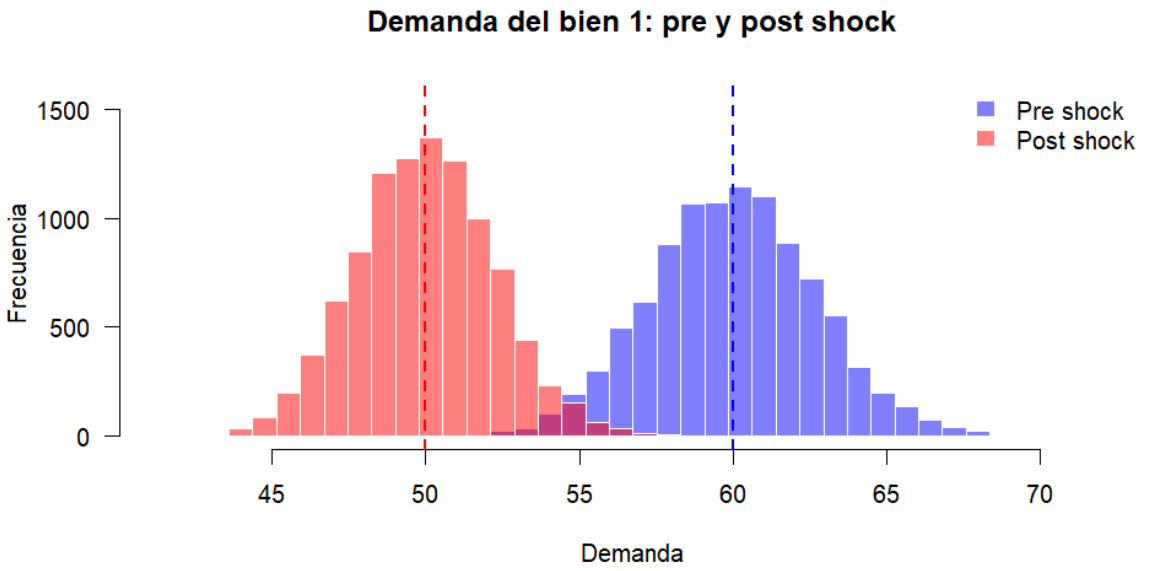


Figura 14: Demanda de x1 pre y post shock

Hogares que consumen poco del bien 1. Como la demanda óptima es $x_1^* = \alpha_1 Y/p_1$, el shock $p_1' = 1{,}2\,p_1$ multiplica la demanda de cada hogar por $1/1{,}2$ y desplaza toda la distribución hacia la izquierda. Con el mismo umbral c, la probabilidad de bajo consumo pasa a ser 0,9992, es decir, casi 1: la distribución se desplazó tanto que casi nadie consume ya tanto como el umbral.

Utilidad indirecta. En promedio, la utilidad de cada hogar cae en 7 unidades.

Heterogeneidad en preferencias

Ahora permitimos que cada hogar tenga su propia preferencia: $\alpha_1 \sim \text{Beta}(a, b)$ con $a = 3$ y $b = 2$, y $\alpha_2 = 1 - \alpha_1$. Mantenemos el mismo ingreso y los mismos precios, y cambiamos únicamente los α.

Para comparar la dispersión y la sensibilidad al shock, corremos el shock de precios también con preferencias heterogéneas (con los mismos Y y los mismos α_1 individuales antes y después) y calculamos los desvíos estándar.

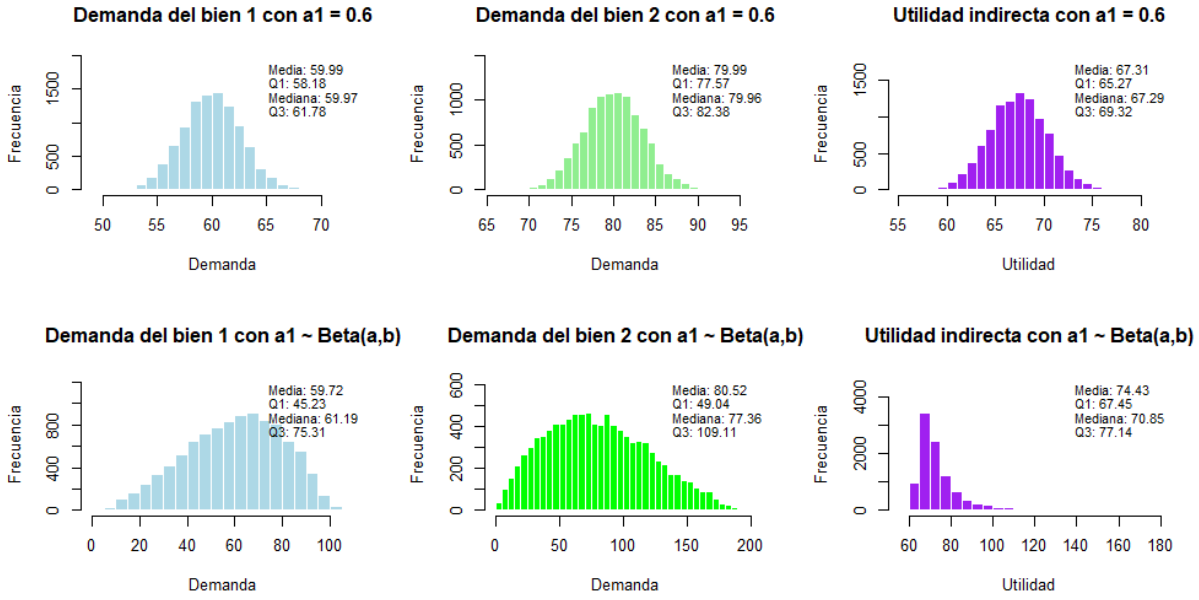


Figura 15: Demandas y Utilidades Comparadas

Dispersión de las demandas. Cuando todos los hogares tienen la misma preferencia ($\alpha_1 = 0{,}6$), la única fuente de variabilidad en la demanda es el ingreso, que con $k = 1000$ es casi constante; por eso el desvío de x_1^* es chico (2,68). Al permitir que α_1 varíe como una Beta(3,2), las demandas mantienen aproximadamente la media, pero las preferencias de los hogares sobre cada bien se vuelven heterogéneas: la dispersión de x_1^* se multiplica por unas 7,6 veces (20,27) y la de la utilidad indirecta por unas 4 (de 3,01 a 11,91).

Utilidad indirecta. Con preferencias homogéneas, la utilidad indirecta se distribuía casi simétricamente alrededor de su media, porque casi toda la variación venía del ingreso. Al variar las preferencias, la utilidad promedio sube y la dispersión aumenta. La intuición es que los hogares que prefieren más el bien 2, que cuesta la mitad que el bien 1 antes del shock, aprovechan mucho mejor su ingreso.

Sensibilidad al shock de precios. Frente al shock del 20 % en p_1, todos los hogares reducen su demanda del bien 1 en la misma proporción, independientemente de sus preferencias (por la forma de la condición de primer orden de la Cobb-Douglas). Lo que sí cambia es cuántas unidades pierde cada uno: como la caída individual es $-x_1^*/6$, el desvío del cambio es el desvío de x_1^* dividido 6, que da 0,447 en el caso homogéneo y 3,379 en el heterogéneo. En el caso homogéneo todos pierden más o menos lo mismo, alrededor de 10 unidades, mientras que con preferencias heterogéneas pierden mucho más los hogares con α_1 alto (los que más querían el bien 1) y casi nada los que lo valoraban poco. La pérdida media es parecida porque la media de α_1 es la misma.

Incisos 4, 5 y 6 con preferencias heterogéneas. Repetimos ahora los incisos 4, 5 y 6 con preferencias heterogéneas. Para la probabilidad de bajo consumo usamos el mismo umbral c que en el caso homogéneo (la media menos un desvío estándar de x_1^* con $\alpha_1 = 0{,}6$), así las cuatro probabilidades son comparables entre sí.

	Pre shock	Post shock
Homogéneo ($\alpha_1 = 0{,}6$)	0,1585	0,9992
Heterogéneo (Beta(3,2))	0,4346	0,6394

Tabla 6: Probabilidad de bajo consumo del bien 1, $P(x_1^* < c)$, antes y después del shock.

Con preferencias homogéneas pasa de 0,16 a 0,999 con el shock: como todos consumen parecido, correr toda la distribución un 20 % hace que casi nadie supere el umbral. Pero con Beta ya había mucha más gente con bajo consumo antes del shock (0,43) y la probabilidad sube a 0,64: el aumento es mucho menor porque, al estar las demandas muy dispersas, el mismo corrimiento (dividir por 1,2) cruza el umbral para una fracción más chica de hogares.

Para el inciso 5, graficamos la demanda del bien 1 antes y después del shock con preferencias heterogéneas, usando el mismo procedimiento que antes: cortes en común y `add = TRUE`.

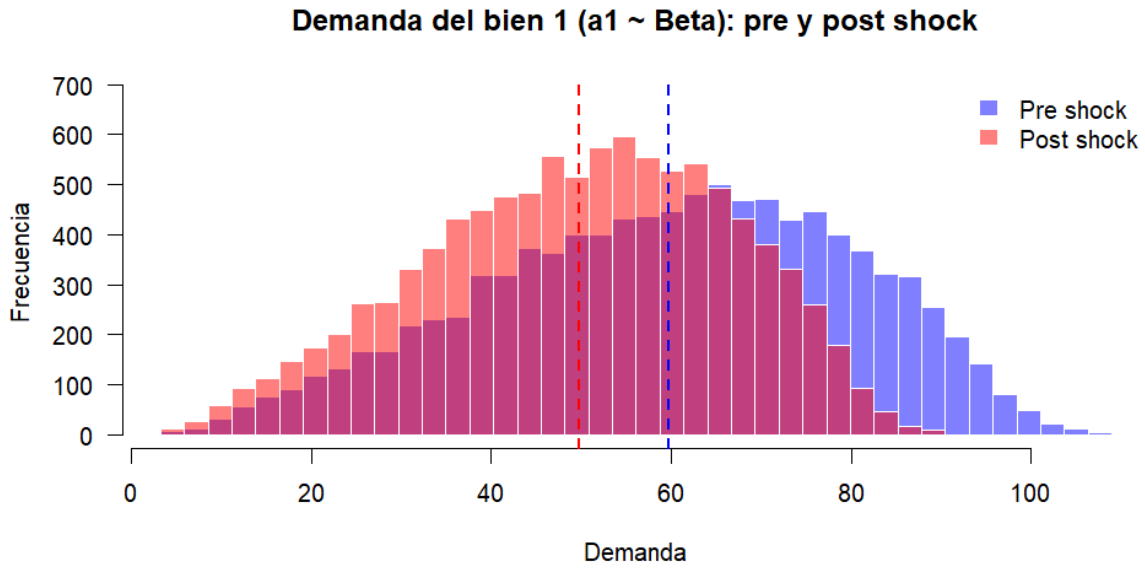


Figura 16: Demanda de x1 pre y post shock con Preferencias Heterogéneas

Para el inciso 6, calculamos el cambio en las medias y en la utilidad indirecta con preferencias heterogéneas.

Cambio medio con el shock	Homogéneo	Heterogéneo (Beta)
Δx_1^*	$-9{,}998$	$-9{,}954$
Δx_2^*	0	0
ΔU^* (unidades)	$-6{,}974$	$-7{,}413$
ΔU^* (porcentaje)	$-10{,}4\,\%$	$-10{,}0\,\%$

Tabla 7: Cambio medio en las demandas y en la utilidad indirecta tras el shock.

El bien 1 cae casi lo mismo en ambos casos ($-9{,}998$ contra $-9{,}954$): como la media de α_1 es la misma (0,6), la demanda media del bien 1 es parecida (alrededor de 60) y la caída es aproximadamente un sexto de eso (alrededor de 10). El bien 2 no cambia en ninguno de los dos casos, porque su demanda no depende de p_1. La utilidad media cae un poco más con Beta en unidades ($-6{,}97$ contra $-7{,}41$), pero eso se debe a que parte de un nivel más alto (74,4 contra

67,3): en porcentaje la caída es similar, algo menor con Beta ($-10{,}0\,\%$ contra $-10{,}4\,\%$). Lo que cambia con la heterogeneidad de preferencias no es la caída media, sino quién pierde más: los hogares con α_1 alto.

Conclusiones de la simulación

1. Bajo Cobb-Douglas, la demanda de cada bien es una fracción fija del ingreso y no depende del precio del otro bien. Por eso el aumento del $20\,\%$ de p_1 reduce x_1^* en un factor $1/1{,}2$ (unas 10 unidades en promedio) y deja intacto x_2^*.

2. Con preferencias homogéneas, el shock desplaza toda la distribución de x_1^* hacia la izquierda y la probabilidad de bajo consumo pasa de 0,16 a 0,999, porque todos los hogares consumen parecido.

3. Con preferencias heterogéneas ($\alpha_1 \sim \text{Beta}(3, 2)$) la dispersión de las demandas y de la utilidad aumenta mucho (el desvío de x_1^* pasa de 2,68 a 20,27), y la probabilidad de bajo consumo sube menos con el shock (de 0,43 a 0,64).

4. La caída media de x_1^* y de la utilidad (cerca de $-10\,\%$) es casi igual con y sin heterogeneidad, pero con heterogeneidad pierden mucho más los hogares con α_1 alto. El promedio esconde quiénes ganan y quiénes pierden.